从制造排产经验
到 AI Agent 落地

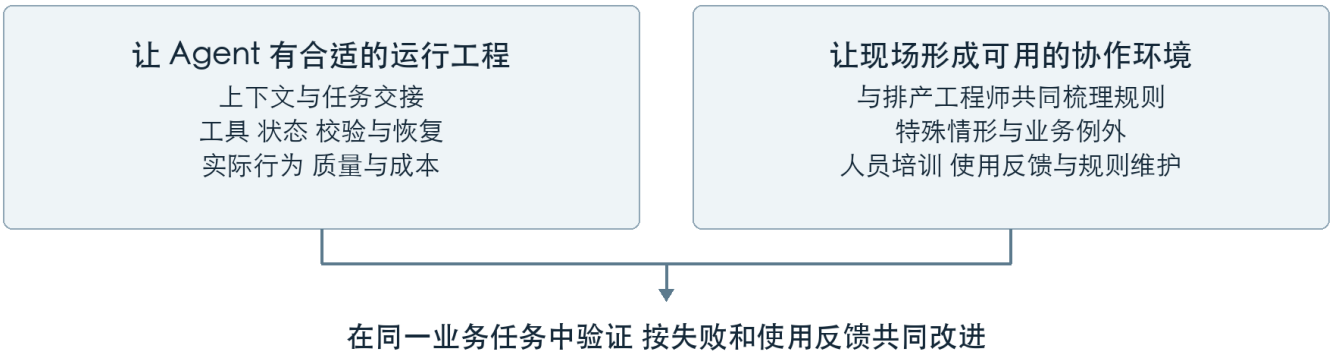
我的职业实践与智能排程工作思路

鄢澳勇 | AI Agent 与大模型应用方向 | 2026 年 10 月 13 日

我理解的合格大模型应用工程师，需要同时承担两方面工作：把模型的能力组织成可以检查、接续和迭代的 Agent；与业务人员一起创造适合 Agent 工作的环境，并帮助使用者建立正确的协作方法。智能排程是我希望把这两方面结合起来探索的场景。

这一想法来自我的职业经历。我做过冷轧专家排产，与专家梳理人工判断、实现规则并参与现场测试；后来做过企业知识库中的数据、模型服务和研究流程交付，也持续建设个人 Harness。它们让我逐步认识到，业务规则、上下文、工具和人的使用方式，都需要纳入应用工程。

我希望承担的两条工作主线



Harness 在本文中指组织 Agent 上下文、工具、任务、状态和反馈的支撑工程；也包含对现成 Agent 能力的适配与验证。

为什么用智能排程继续探索

当前排程项目已经经历初期受阻、工程修订和后续成功推进，提供了研究模型能力与运行方式的具体样本。它仍在进行中：短窗口运行成功之后，还需要解决长期运行、调用成本、公平比较和真实使用的问题。

如果入职，我会把这项探索与现场工作结合：一边改进排程 Agent 的运行工程，一边与排产工程师共同梳理规则、积累特殊案例、开展试用和培训。两条线在同一个业务任务上持续核对，逐步形成可用的应用。

本文先说明已有经验与工作，再展开工程、现场和培训三部分。源码、实验记录及调研细节见第 7 页 GitHub 阅读入口。

1 我的已有经验怎样连接到这项工作

我的经历可以用同一条工作方法串起来：理解专业人员怎样判断，把必要信息和规则组织成系统，再由真实任务检验结果。技术手段从 C++、RAG、模型服务延伸到 Agent，这条方法一直是我关注的重点。

已有工作	我实际负责的内容	带到排程 Agent 的经验
制造专家排产	福欣特殊钢冷轧项目中的 C++/MFC 页面、专家判断梳理、规则与数据库配置、现场功能和业务测试	与排产人员沟通隐性规则 把业务判断转成可执行逻辑 核对现场行为
企业知识库交付	规划成果知识库的数据治理、任务级模型训练评测、本地 vLLM 服务、LangGraph 研究流程	组织专业材料与来源 适应实际服务限制 让业务人员参与结果验收
法律政策 RAG	数据清洗、分块与检索比较、评价校准、生成与端到端验证	区分信息缺失 检索错误 推理错误与评价问题 按错误所在环节改进
个人 Harness	需求、关键设计与取舍、质量边界和终验；AI 主要实现代码、测试与文档，曾向公司人员分发	把目标与材料交接清楚 核对工具是否真正被采用 关注协作与维护成本

两段经历对我影响尤其直接

在冷轧项目中，业务基础上已有 MES，但部分排产判断仍依靠专家经验。我参与将这些判断转成规则，并配合现场人员测试。这让我在新场景中会先看排产人员实际怎样工作，关注规则的适用条件和例外，再确定系统如何支持。已有制造经验是专家规则自动化，半导体工艺及其约束仍需重新学习和核实。

在规划知识库中，甲方服务曾只提供有限的上下文空间，我通过任务拆分、知识组织和模型分工适应这些约束。在 Harness 实践中，又发现提供知识工具并不保证 Agent 实际使用。这让我把上下文工程理解为：给什么信息、怎样获取、何时提供，以及信息是否真正影响了任务执行。

当前正在推进的工作

我将这些经验带入智能排程探索，推动比较经典算法、模型直接排程和模型调用工具，补充公开基准与半导体仿真场景，并追问失败原因、比较条件与成本。代码实现、实验运行和资料整理大量由 Codex 辅助完成；我重点承担问题定义、研究方向、关键取舍与结果审查。后续专用 Harness 仍在讨论与验证阶段。

2 排程试验让我看到的工程问题

我使用 Codex 辅助推进排程原型，比较 A 经典算法、B 模型直接决定排程、C 模型调用排程工具三种方式。试验既暴露了使用通用 Agent 组织工作的困难，也留下了排程 Agent 自身运行协议的问题。两者都需要工程改进。

通用 Agent 的协作方式也需要设计

在使用 Codex 推进试验时，初次尝试因上下文组织、任务分配等问题受阻，调整后才成功推进。这让我把任务怎样交给 Agent、已有工作怎样被下一步接住，也纳入工程设计：将临时修正沉淀成可重复的方法，并用后续任务检验。

排程运行协议中的具体问题

运行中发生的事情	具体记录与意义
工作记忆字段超限	B 的一次早期运行因 memory 字段达到 8,700 字符、超过协议的 8,192 字符上限而停止，尚未提交计划。这是应用协议中的字段限制，不能等同于模型总上下文耗尽。
重复读取与计划交接	后续开发持续处理记忆、重复读页、基准计划供给和状态交接问题。已有计划怎样被下一轮准确获取，是推进任务需要解决的工程问题。
修订后完成开发窗口	多轮修订与续跑后，B 完成一个场景的一小时仿真窗口，承担 913 台设备的排程责任，来源、物理与归属检查通过。完整正式对照仍未完成。

这些记录支持继续研究 Harness，但尚不能把后续成功全部归因于某一次上下文修改：过程中还涉及控制器、协议、恢复及预算等变化。它们为工程改进提供了问题清单，具体改动的价值还需单独比较。

运行成功之后仍然有成本问题

整个 B 一小时开发沿革记录了 1,362 次模型尝试，已知输入与输出合计约 4,467 万 tokens，另有 3 次历史用量未知。这个数字包含开发与恢复过程，不代表以后单次运行的固定成本，却说明成功推进仍可能伴随大量交互。后期相同协议片段平均一次提交需要约 9.74 次模型调用。

我会据此检查哪些步骤需要模型判断，哪些只是机械的建草稿、检查、存储和提交；同时检查计划、已确认事实与未完成任务怎样保留，避免每轮重新寻找同一批信息。压缩开销后还要复核决策质量与约束，不能只看 token 数下降。

把任务分工也纳入验证

一部分问题出现在辅助研发中的角色分工和交接，一部分出现在排程 Agent 的运行协议。后续我会分别定义开发任务的目标、依赖与验收，以及排程任务的状态、权限与提交条件；复用已验证的方法，再针对排程补齐缺口。

证据：公开仓库中的全厂开发报告、B 一小时效率报告与当前项目状态，见第 7 页。仿真一小时不代表现实一小时内完成，亦不代表已具备生产收益或实时调度能力。

3 我会怎样建设适合排程的 Harness

我的目标是让 Agent 在恰当的信息、工具和反馈下完成任务。先沿一条真实任务路径补齐必要能力，再根据故障和使用记录迭代。已有 Harness 也经历过控制设计过多、维护负担增加的教训，因此我会先核对宿主能力，明确哪些职责需要新增。

工程工作	我会落实的内容	用什么检验
上下文组织	长期规则按版本管理；任务只携带相关状态、目标和限制；原始资料可回查；已确认事实与未决问题分开保存	必要约束是否保留 是否重复读取 信息是否被实际采用
任务与交接	为任务写清输入、输出、边界、依赖、验收和预算；只有可独立完成的部分才拆分给其他 Agent	是否重复或遗漏工作 交接能否继续执行 是否扩大了任务范围
工具与动作	信息查询、方案生成、检查和执行接口职责明确；机械操作适度合并，错误反馈可供下一步修订	工具是否真正被调用 每次提交的往返数 决策责任是否清楚
状态与恢复	保存候选、检查结果、已提交动作和剩余工作；状态过期重新检查；提交结果未知时先核实回执	中断后能否正确接续 是否重复执行 旧计划是否被误用
评价与演进	保留版本、轨迹和失败；同时看合法性、业务质量、时延、费用及人工介入	改动是否改善真实任务 旧问题是否重新出现 维护成本是否可接受

给模型发挥能力的空间 也明确程序的责任

对于需要探索的任务，我希望模型能根据中间结果规划下一步、组合工具和修订方案。确定性程序负责适合计算核对的事项，例如字段、状态版本、已定义约束和提交记录；现场专业判断及关键取舍由人确认。稳定重复的环节可以固化为工作流，探索步骤则保留调整空间。

排程决策继续比较 B 直接决策、C 调用工具和离线规则生成。C 要与同工具固定策略比较，判断模型是否有额外价值；B 要明确程序有没有替模型重新选机或排序。路线选择依据相同条件下的质量、成本和响应要求，当前不预先确定唯一方案。

先做能被重复检查的一条路径

首个原型完成状态读取、任务澄清、候选生成、独立检查、人工审核和记录。随后用上下文过长、规则冲突、工具超时与状态变化等案例检验它。一次顺利演示之后，还要检查中断、修订和交接能否保持正确。

4 与现场工程师共同创造应用环境

我会把现场规则整理视为应用开发的一部分。冷轧排产经历让我知道，专家的判断不一定完整写在制度或系统里。因此入职初期，我会与排产工程师一起走完正常排产和异常调整，了解他看到什么信息、为什么这样安排，以及什么时候会改变原决定。

跟着实际任务收集规则与特殊情况

先选一个边界清楚的设备组或重排任务，记录每一步判断，并比较工程师方案与 Agent 建议的差异。特别追问插单、停机、质量挂起、临时资格变化等情形；这些是待现场核实的候选案例，不能默认其具体规则适用于目标工厂。

当双方判断不同，我会先固定同一份输入和规则版本，再区分信息缺失、规则未表达、目标冲突、模型推理或工具实现问题。对尚无一致意见的情况，保存为待确认案例，由对应业务负责人裁决，不让临时聊天中的一句补充直接变成长期生产规则。

把一条经验整理成可维护的规则

需要讲清的内容	与现场人员共同确认的事项
适用范围与依据	哪些产品 设备 工步适用；规则来自谁；何时生效
必要条件与例外	需要哪些状态；必须满足什么；什么情况下例外
冲突与缺失	与其他规则矛盾时谁裁决；信息不足时如何处理
例子与验证	正常案例 反例 特殊情形；预期结果及认可人
变更与维护	规则负责人 有效版本 更新方式和受影响的测试

按用途把现场知识放到合适的位置

实时批次与设备状态由可信业务接口提供；硬约束进入可检查的规则或校验程序；经验、说明与历史案例组织为按需查阅的材料；目标优先级和一次性例外通过任务入口明确。现场人员需要能查看依据、提出纠正，并知道改动由谁确认。

例如设备故障后的重排，我会先与工程师核实停机范围、可替代机台、已开工任务和交期要求，再让 Agent 生成建议。复核时不仅看当前是否可执行，也检查对上下游和原计划的影响。经过确认的新情形沉淀为规则、案例或工具改进，使下一次任务有更完整的环境。

交付物包括现场流程图、规则与例外清单、版本化案例集及数据接口说明。它们与 Harness 同步建设，由真实排产任务共同验证。

5 把使用者培训纳入交付

我曾把个人 Harness 分发给公司人员使用。这使我希望在排程应用中进一步承担使用方法的交付：让工程师知道怎样提出任务、怎样提供和更新上下文、怎样核对结果，以及何时应该停止自动推进并接管。以下是我拟开展的培训安排。

培训主题	使用者需要学会的动作	练习与检查
说清任务	说明目标、范围、期限和不可改动内容；区分建议与执行请求	用真实案例提出请求 能识别尚缺的信息
管理上下文	选择有效状态和规则；保留必要限制；区分确认事实、假设与一次性例外	找出过期或冲突信息 正确补充变化
检查方案	核对受影响批次、依据、假设与取舍；查看检查结果和未解决项	解释接受或拒绝原因 发现遗漏的现场条件
纠偏与交接	指出具体差异；任务变更后重新确认范围；中断时交接当前状态和未完项	接续一次中断任务 不重复已完成动作
维护与反馈	按规定提交新案例或规则修订；知道找业务负责人还是技术维护者	用一份问题记录 复现并归类故障

用一个排程任务讲解上下文工程

培训示例：设备组 G 临时停机，需要调整本班未开工批次。使用者在任务入口选择现场确认的状态快照 S1，指定交期目标和冻结安排，并说明只生成待审核建议。系统提供相关规则与工具结果，缺失的停机恢复时间保持为待确认项。G 与 S1 仅为示例标识。

若恢复时间改变，使用者明确说明变化并重新确认目标，系统刷新状态、重新检查旧候选。若要开启另一项排程任务，应使用独立任务及其状态；需要延续原任务时，则保留目标、关键约束、已提交动作、未决问题和来源，不把全部聊天记录反复粘贴过去。

将培训结果反馈到产品与工程

系统应自动提供版本、状态更新和约束检查等保障，让使用者通过任务表单、规则选择和解释页面完成工作。培训帮助他们判断信息是否完整、结果是否适用；若多人反复犯同一种错误，我会检查界面、默认设置和上下文供给方式，并改进系统。

培训采用共同操作、引导练习、独立案例与复盘。排产人员重点学习任务和结果判断，规则负责人学习例外确认与维护，技术人员学习诊断与恢复。验收既看能否独立完成任务，也看能否发现异常、正确接管以及说明决策依据。

6 下一步推进与工作资料入口

如果入职，我会选择一个真实任务，让工程、业务规则与人员使用同步推进。每阶段完成的材料和运行记录应足以支持下一步决定；具体周期在现场需求、数据和接口条件明确后确定。

阶段	共同推进的工作	判断是否继续的依据
共同梳理	与工程师一起排产 整理规则 例外及现行流程	试点范围明确 关键状态和验收目标可确认
离线共测	完善 Harness 最小路径 历史案例回放 失败与恢复验证	规则检查可信 质量 时延与成本支持试用
现场辅助	只读影子运行与使用培训 记录建议 纠正和拒绝原因	工程师能理解并核对结果 发现异常时能正确处理
受控使用	限定场景审核执行 根据新问题更新规则与工程	业务价值与运行表现达标 维护责任和成本清楚

评价同时覆盖排程质量、硬约束、响应期限、恢复正确性、全尝试成本，以及工程师处理时间和修改负担。历史回放与影子运行先帮助找问题，真实收益还需适当的仿真或受控使用验证。扩大范围时，重新核对业务影响和人员准备情况。

现有工作可以怎样查阅

GitHub 智能排程与 Harness 研究归档

报告、代码快照、决策记录及公开会话资料。项目仍在推进，阅读资料不需要先运行实验。

先看项目当前状态

了解各阶段完成范围、仍保留的失败和限制，避免把局部或短窗口结果当成全厂项目完成。

深入看排程失败与成本复盘

查看直接排程的完成范围、调用成本、上下文与交互协议瓶颈，以及后续验证建议。

查看 Harness 路线调研与未决问题

了解为什么仍保留 B、C 与离线规则路线，以及下一步需要补足的证据。

材料依据与当前边界

职业经验部分来自我的制造排产、企业知识库交付与个人 Harness 实践记录。当前排程试验的数据与限制可在上述公开仓库查阅。现场规则共建、人员培训与专用 Harness 是下一步计划，具体范围将结合现场需求确定。

上下文工程参考：Anthropic 工程文章

核阅日期 2026-10-13。参考信息组织与长任务管理的讨论；其通用建议不构成本项目效果证明。